

---

# Base Ouro - Grupo 5

Relatório técnico e interpretativo

V1 oficial | V2 complementar

Fechamento: 04/10/2026

Escopo exclusivo da base Ouro. Nenhum tuning, treinamento ou walk-forward foi reexecutado.


# 1. Resumo executivo

Este relatório trata exclusivamente da base Ouro do Grupo 5. A V1 permanece a modelagem oficial; a V2 entra apenas como estudo complementar para explicar dificuldade do alvo, extrapolação do Random Forest, ablation, drift e redundância. Nenhum resultado congelado foi recalculado.

No teste final, Holt-Winters obteve o menor MAE, 11,5331 USD/onça troy, seguido de SARIMAX (11,5988), PLS Regression (11,6002) e Random Forest (14,2826). Persistência marcou 11,6377 e permanece fora do ranking. A vantagem do primeiro colocado sobre persistência foi somente 0,90%, de modo que Holt-Winters, SARIMAX e PLS devem ser apresentados como resultados muito próximos, não como uma vitória ampla.

O achado central é interpretativo: em horizonte de uma observação, o preço recente domina; a dificuldade cresceu no período de teste; e o RF em LEVEL encontrou um regime no qual quase todos os alvos ultrapassavam o máximo observado no treino. A V2 reforça essa leitura, mas não substitui a V1.

| model          | n_forecasts | mae     | rank_gold |
|----------------|-------------|---------|-----------|
| Holt_Winters   | 296         | 11.5331 | 1         |
| SARIMAX        | 296         | 11.5988 | 2         |
| PLS_Regression | 296         | 11.6002 | 3         |
| Random_Forest  | 296         | 14.2826 | 4         |



## 2. Base, qualidade e causalidade temporal

O alvo é o preço do ouro na próxima observação real do calendário bruto. A série corresponde ao fixing da tarde de Londres da Deutsche Bundesbank, código BBEX3.D.XAU.USD.EA.AC.C05, em USD por onça fina. O arquivo usado cobre 01/04/1968 a 10/04/2014.

Dos 12.009 registros brutos, 11.641 têm preço válido e 368 estão ausentes. O ouro não foi interpolado. A base modelável final tem 9.864 observações e 12 features causais. Treasury 10Y e Fed Funds foram alinhadas ao calendário do ouro por `left merge`, preenchidas somente para frente e defasadas uma observação. Não houve `backfill`.

A auditoria reconstruiu todas as linhas e confirmou que `TARGET = GOLD_PRICE.shift(-1)` foi criado antes do filtro modelável. Em 428 casos, o alvo não coincide com a próxima linha modelável, mas continua apontando corretamente para o próximo preço do calendário bruto. Não foi encontrada evidência de leakage, deslocamento temporal ou previsão não finita.




### 3. STL, features e prevenção de leakage

A STL foi ajustada somente no treino. Nos períodos 5, 20 e 252, a força sazonal foi 0,0; a tendência foi o componente dominante. O período 5 permaneceu como referência operacional de semana de mercado em algumas configurações, não como evidência de sazonalidade forte.

RF e PLS usam a mesma matriz de 12 features: nível atual, lags 1/5/20, média e desvio móvel dos cinco preços anteriores, calendário cíclico e duas externas. As janelas usam `shift(1)` antes do cálculo; `TARGET` e `TARGET_UP` não entram como features. O PLS reajusta o `StandardScaler` dentro de cada janela de treino.

| period | seasonal_strength | trend_strength | residual_std |
|--------|-------------------|----------------|--------------|
| 5      | 0.0000            | 0.9984         | 6.0593       |
| 20     | 0.0000            | 0.9907         | 14.3810      |
| 252    | 0.0000            | 0.9225         | 41.6081      |

STL robusta no treino - período 5





## 4. Protocolo experimental e tuning congelado

A base foi dividida cronologicamente em 70% treino, 15% validação e 15% teste. O walk-forward usa janela expansiva, horizonte de uma observação e passo cinco, com 296 origens de validação e 296 de teste. Os quatro modelos compartilham origens, datas-alvo e Y\_TRUE.

Tuning ocorreu somente em treino e validação. O teste final avaliou configurações congeladas: SARIMAX  $(0, 1, 2) \times (0, 0, 1, 5)$ ; Holt-Winters aditivo com período 5; RF com 300 árvores, profundidade 20, folha mínima 5, divisão mínima 10 e `max_features=1.0`; PLS com 11 componentes. Nenhuma decisão foi reaberta nesta finalização.

| model          | validation_mae | n_candidates |
|----------------|----------------|--------------|
| SARIMAX        | 2.9844         | 5            |
| Holt_Winters   | 2.9760         | 15           |
| Random_Forest  | 3.3263         | 12           |
| PLS_Regression | 2.9701         | 12           |



## 5. MAE, persistência e mudança de dificuldade

MAE está expresso em USD por onça troy. Nas mesmas 296 origens de teste, o movimento absoluto médio origem-alvo foi 11,6377 e a mediana foi 8,50. Holt-Winters teve MAE equivalente a aproximadamente 99,1% desse movimento médio: é o menor erro formal, mas sua melhora sobre persistência foi inferior a 1%.

O PLS teve MAE de validação 2,9701 e MAE de teste 11,6002. Não há mudança de unidade: são dois blocos temporais diferentes. O histórico completo teve movimento absoluto médio de cerca de 3,8893 USD/onça, contra 11,6377 nas origens oficiais de teste. A diferença mostra aumento importante de escala e volatilidade no teste, sem provar uma causa econômica específica.

Persistência é diagnóstico, não quinto modelo oficial. Ela é especialmente relevante para preços em horizonte curto e impede que pequenas diferenças sejam interpretadas como grande ganho preditivo.


| model          | mae     | baseline_persistence_mae | improvement_pct_vs_persistence |
|----------------|---------|--------------------------|--------------------------------|
| Holt_Winters   | 11.5331 | 11.6377                  | 0.8986                         |
| SARIMAX        | 11.5988 | 11.6377                  | 0.3336                         |
| PLS_Regression | 11.6002 | 11.6377                  | 0.3219                         |
| Random_Forest  | 14.2826 | 11.6377                  | -22.7275                       |

## 6. Resíduos e Ljung-Box

Os resíduos fora da amostra são  $real - previsto$ . Holt-Winters e PLS tiveram média próxima de zero e nenhuma rejeição nos 20 lags avaliados. SARIMAX teve uma rejeição isolada. RF apresentou três rejeições, maior dispersão e viés médio positivo, compatível com subestimação média e estrutura residual remanescente.

O Ljung-Box avalia autocorrelação conjunta até cada lag. Ausência de rejeição não prova independência perfeita; rejeições pontuais também não bastam para explicar todo o erro. A tabela completa de 80 resultados fica no apêndice técnico.

| model          | media_residuos | desvio_padrao_residuos | rejected_lags_5pct | p_value_lag_20 |
|----------------|----------------|------------------------|--------------------|----------------|
| Holt_Winters   | 0.1131         | 15.7363                | 0                  | 0.4041         |
| PLS_Regression | 0.2337         | 15.8807                | 0                  | 0.3550         |
| Random_Forest  | 3.1615         | 20.5757                | 3                  | 0.4008         |
| SARIMAX        | 0.3621         | 15.7470                | 1                  | 0.3162         |







## 7. Importância das features

No RF, a importância nativa é dominada por GOLD\_PRICE e GOLD\_LAG\_1. No PLS, coeficientes padronizados, VIP e permutation importance destacam preço atual, lag 1, média móvel e lags 5/20. A leitura é coerente com um horizonte de uma observação, no qual persistência e memória recente são fortes.

Importância não implica causalidade. Features correlacionadas podem dividir importância; sinais de coeficientes podem variar sob colinearidade; e externas com contribuição marginal pequena neste recorte não são evidência de ausência de relação econômica em outros regimes ou horizontes.

| model          | feature             | vip_score | permutation_rank |
|----------------|---------------------|-----------|------------------|
| PLS_Regression | GOLD_PRICE          | 1.5003    | 1                |
| PLS_Regression | GOLD_LAG_1          | 1.4993    | 2                |
| PLS_Regression | GOLD_ROLLING_MEAN_5 | 1.4979    | 3                |
| PLS_Regression | GOLD_LAG_5          | 1.4958    | 4                |
| PLS_Regression | GOLD_LAG_20         | 1.4855    | 5                |
| Random_Forest  | GOLD_PRICE          |           | 1                |
| Random_Forest  | GOLD_LAG_1          |           | 2                |
| Random_Forest  | FED_FUNDS_RATE      |           | 3                |
| Random_Forest  | GOLD_ROLLING_STD_5  |           | 4                |
| Random_Forest  | DOW_COS             |           | 5                |






## 8. PLS Regression: papel técnico e bloco didático reservado

PLS constrói componentes latentes orientados pela covariância entre X e y, o que ajuda quando preço atual, lags e médias móveis são correlacionados. Na V1, usou as mesmas 12 features causais do RF, com padronização reajustada em cada janela. A validação selecionou 11 componentes; portanto, a compressão foi pequena, 11 de 12 dimensões.

No teste, PLS marcou 11,6002, apenas 0,0671 acima de Holt-Winters e 0,0375 melhor que persistência. Coeficientes, VIP e permutação são leituras complementares e devem ser interpretados com cautela diante da colinearidade e da mudança temporal.

**Bloco reservado - Explicação didática de PLS Regression. A aula completa será incorporada posteriormente a partir do outro chat. O roteiro reserva 3 a 4 minutos para componentes latentes, colinearidade, padronização e leitura dos 11 componentes.**




## 9. V2 complementar: LEVEL, DELTA e LOG\_RETURN

A V2 foi concluída como estudo complementar no commit d6f67bd. Ela não reabre o ranking V1. No RF A8, transformar LEVEL em DELTA ou LOG\_RETURN reduziu fortemente o erro reconstruído em preço: 39,5007 no nível, 12,1579 em delta e 11,7850 em log-retorno. Mesmo assim, DELTA e LOG\_RETURN A8 não superaram persistência.

O menor MAE experimental foi RF/LOG\_RETURN/A3, 11,2986, ganho de 0,3390 USD/onça (2,91%) sobre persistência e acurácia direcional de 53,72%. Esse resultado é INFORMATIVE, pois surgiu em especificação experimental posterior. Ele orienta pesquisa futura, mas não é sucessor oficial de Holt-Winters.

| feature_set              | target     | mae_usd | directional_accuracy | status      |
|--------------------------|------------|---------|----------------------|-------------|
| A8_technical_all_core    | LEVEL      | 39.5007 | 0.5169               | INFORMATIVE |
| A8_technical_all_core    | DELTA      | 12.1579 | 0.4932               | INFORMATIVE |
| A8_technical_all_core    | LOG_RETURN | 11.7850 | 0.5304               | INFORMATIVE |
| A3_gold_technical_no_raw | LOG_RETURN | 11.2986 | 0.5372               | INFORMATIVE |



A3 LOG\_RETURN é informativo e não substitui o ranking oficial V1.

## 10. V2 complementar: ablation, extrapolação, drift e redundância


Na ablation RF LEVEL FULL, remover GOLD\_PRICE piorou o MAE em 2,0914 USD/onça, cerca de 14%. Remover todos os lags trouxe melhora pequena de 0,2929, mas o resultado continuou pior que persistência. Usar somente exógenas produziu MAE 38,1406. Mais features não garantiram melhora, e exógenas não substituíram a dinâmica autorregressiva neste horizonte.

No diagnóstico RF A8,  $y_{\text{train}}$  variou de 252,90 a 725,75 e  $y_{\text{test}}$  de 647,75 a 1.877,75. Em 281 de 296 origens, 94,9%, o alvo real superou o máximo visto no treino. Como árvores predizem por médias em folhas, não extrapolam naturalmente novos níveis. Drift em WTI, juros, dólar, índice acionário e volatilidade do ouro agravou a mudança de distribuição.


Também houve redundância: DGS2 e seu lag 1 ( $\sim 0,9997$ ), VIX e seu lag ( $\sim 0,9818$ ), e distância da média 20 com momentum 10 ( $\sim 0,9289$ ). A estabilidade temporal das importâncias é NOT\_ASSESSABLE\_SINGLE\_TEST\_PERIOD; há um único período de teste, logo drift e permutação são diagnósticos descritivos.

| feature_set             | mae_usd | absolute_difference_vs_full | n_features |
|-------------------------|---------|-----------------------------|------------|
| FULL                    | 14.9906 | 0.0000                      | 39         |
| FULL_without_GOLD_PRICE | 17.0820 | 2.0914                      | 38         |
| FULL_without_gold_lags  | 14.6976 | -0.2929                     | 23         |
| A4_exogenous_only       | 38.1406 | 23.1500                     | 7          |

| feature           | standardized_mean_shift |
|-------------------|-------------------------|
| DCOILWTICO        | 3.4250                  |
| DGS2              | -2.1746                 |
| dgs2_lag1         | -2.1710                 |
| yield_curve_slope | 1.3751                  |
| DTWEXB            | -1.1297                 |
| gold_rv_60        | 1.0256                  |
| NASDAQCOM         | 0.8929                  |
| gold_rv_20        | 0.8580                  |



### V2: extrapolação e mudança de distribuição no RF A8



## 11. Validação V2 e ressalva de metadado

A evidência final da V2 registra 99 experimentos canônicos, todos com 296 origens, previsões finitas, origens únicas, MAE reproduzido e reconstrução correta de preço para DELTA e LOG\_RETURN. A Stage B está concluída; o antigo V2\_STATUS.md com itens deferred/not run ficou desatualizado diante dos achados e da validação final de d6f67bd.

**O estado correto é PASS\_WITH\_METADATA\_RECONCILIATION\_REQUIRED. Nos arquivos brutos V2, target\_date contém a data da origem. As tabelas consolidadas recuperam a data-alvo correta pelo manifesto V1 congelado. A reconciliação altera apenas o rótulo de metadado: previsões, Y\_TRUE, as 296 origens e os MAEs permanecem intactos.**

| Status                                     | Experimentos | Origens | V1 intacta |
|--------------------------------------------|--------------|---------|------------|
| PASS_WITH_METADATA_RECONCILIATION_REQUIRED | 99           | 296     | True       |

---

## 12. Limitações e conclusão

As conclusões estão limitadas à série histórica até 2014, horizonte de uma observação e calendário irregular. As externas seguem regra conservadora, sem vintages intradiários completos. O ganho do melhor modelo sobre persistência é pequeno. A importância não é causal e sua estabilidade entre regimes não foi demonstrada. A V2 explorou um único teste e não autoriza seleção pós-teste.

A conclusão oficial permanece: Holt-Winters 11,5331; SARIMAX 11,5988; PLS 11,6002; Random Forest 14,2826. Persistência marcou 11,6377 fora do ranking. Os três primeiros ficaram praticamente empatados. RF em LEVEL foi prejudicado por extrapolação, drift, redundância, maior dispersão e estrutura residual remanescente.

A V2 mostra que DELTA e LOG\_RETURN são caminhos promissores para um protocolo futuro com seleção pré-teste, períodos independentes e dados mais recentes. Nesta entrega, V1 é a referência oficial e V2 é explicação complementar.

---

## 13. Referências, apêndice e governança

As referências completas estão em `REFERENCIAS_OURO.md`, separadas entre fonte institucional, URL de aquisição, séries externas, artigos e bibliotecas. O apêndice técnico lista protocolo, tuning, resíduos, Ljung-Box, auditorias, V2, hashes e ressalvas. O checklist distingue requisitos locais de itens dependentes das cinco bases ou do grupo.

Artefatos congelados protegidos: `base modelada`, `predictions.csv`, `metrics.csv`, `hyperparameters.csv`, `protocol.json` e os 24 notebooks técnicos da V1. A finalização não executou tuning, treinamento, walk-forward ou otimização.

Documentos associados: `APENDICE_TECNICO_OURO.md`, `CHECKLIST_ATIVIDADE_OURO.md`, `ROTEIRO_APRESENTACAO_OURO.md`, `REFERENCIAS_OURO.md` e `MANIFESTO_ENTREGA_OURO.md`.