

Base Ouro - Grupo 5

Relatório local e estudo de caso: V1 oficial, V2 complementar

Fechamento: 04/10/2026

Escopo: exclusivamente Grupo 5 / Ouro

Regra de leitura: V1 define o ranking oficial; V2 explica limitações e caminhos futuros.


1. Resumo executivo

Este relatório trata exclusivamente da **base Ouro do Grupo 5**. A V1 permanece a modelagem oficial; a V2 entra apenas como estudo complementar para explicar dificuldade do alvo, extrapolação do Random Forest, ablation, drift e redundância. Nenhum resultado congelado foi recalculado.

No teste final, Holt-Winters obteve o menor MAE, 11,5331 USD/onça troy, seguido de SARIMAX (11,5988), PLS Regression (11,6002) e Random Forest (14,2826). Persistência marcou 11,6377 e permanece fora do ranking. A vantagem do primeiro colocado sobre persistência foi somente 0,90%, de modo que Holt-Winters, SARIMAX e PLS devem ser apresentados como resultados muito próximos, não como uma vitória ampla.

O achado central é interpretativo: em horizonte de uma observação, o preço recente domina; a dificuldade cresceu no período de teste; e o RF em LEVEL encontrou um regime no qual quase todos os alvos ultrapassavam o máximo observado no treino. A V2 reforça essa leitura, mas não substitui a V1.

model	n_forecasts	mae	rank_gold
Holt_Winters	296	11.5331	1
SARIMAX	296	11.5988	2
PLS_Regression	296	11.6002	3
Random_Forest	296	14.2826	4



2. Base, qualidade e causalidade temporal

O alvo é o preço do ouro na próxima observação real do calendário bruto. A série corresponde ao fixing da tarde de Londres da Deutsche Bundesbank, código `BBEX3.D.XAU.USD.EA.AC.C05`, em USD por onça fina. O arquivo usado cobre 01/04/1968 a 10/04/2014.


Dos 12.009 registros brutos, 11.641 têm preço válido e 368 estão ausentes. O ouro não foi interpolado. A base modelável final tem 9.864 observações e 12 features causais. Treasury 10Y e Fed Funds foram alinhadas ao calendário do ouro por `left merge`, preenchidas somente para frente e defasadas uma observação. Não houve `backfill`.

A auditoria reconstruiu todas as linhas e confirmou que `TARGET = GOLD_PRICE.shift(-1)` foi criado antes do filtro modelável. Em 428 casos, o alvo não coincide com a próxima linha modelável, mas continua apontando corretamente para o próximo preço do calendário bruto. Não foi encontrada evidência de leakage, deslocamento temporal ou previsão não finita.

item	valor	detalhe
periodo_serie_bruta	1968-04-01 a 2014-04-10	período do arquivo de referência, incluindo datas com preço ausente
registros_brutos	12009	todas as linhas do arquivo de ouro
registros_com_preco_valido	11641	linhas com GOLD_PRICE numérico
registros_modelaveis	9864	linhas após exigir alvo, lags, janelas e externas causais disponíveis
frequencia_observada	dias de mercado, calendário irregular	mediana do intervalo entre preços válidos = 1 dia(s)
unidade	USD por onça fina de ouro	unidade oficial documentada para a série
fonte	CSV de referência gold.daily.prices.csv	fixing da tarde em Londres; código BBEX3.D.XAU.USD.EA.AC.C05
significado	preço diário do ouro no fixing da tarde em Londres	série de preço, não retorno
duplicidades_data_bruta	0	datas repetidas no arquivo bruto
duplicidades_data_modelavel	0	datas repetidas na base usada pelos modelos
precos_ausentes	368	não imputados; linhas excluídas da base modelável
maior_intervalo_modelavel_dias	20	irregularidade de calendário observada após a filtragem causal
intervalos_modelaveis_maiores_que_3_dias	401	feriados, fins de semana prolongados e lacunas da série
extremos_nivel_preco_iqr	1416	sinaliza regimes de nível; não implica erro de dado
retornos_extremos_mad	480	movimentos incomuns preservados por não haver evidência de erro

verificação	valor
linhas no arquivo bruto	12009
preços ausentes no arquivo bruto	368
linhas na base modelada	9864
nulos na base modelada	0
datas duplicadas	0
maior intervalo entre observações (dias)	20
intervalos maiores que 3 dias	401
extremos pelo IQR no nível do preço	1416
retornos extremos pelo MAD	480

Preço diário do ouro ao longo do tempo



3. STL, features e prevenção de leakage


A STL foi ajustada somente no treino. Nos períodos 5, 20 e 252, a força sazonal foi 0,0; a tendência foi o componente dominante. O período 5 permaneceu como referência operacional de semana de mercado em algumas configurações, não como evidência de sazonalidade forte.

RF e PLS usam a mesma matriz de 12 features: nível atual, lags 1/5/20, média e desvio móvel dos cinco preços anteriores, calendário cíclico e duas externas. As janelas usam `shift(1)` antes do cálculo; `TARGET` e `TARGET_UP` não entram como features. O PLS reajusta o `StandardScaler` dentro de cada janela de treino.

period	seasonal_strength	trend_strength	residual_std
5	0.0	0.9984	6.0593
20	0.0	0.9907	14.3810
252	0.0	0.9225	41.6081

nome	tipo	informacao_usada	conhecida_na_origem
GOLD_PRICE	preço observado na origem	preço do ouro disponível na origem	sim
TREASURY_10Y	variável externa defasada	último DGS10 disponível antes da origem	sim
FED_FUNDS_RATE	variável externa defasada	último DFF disponível antes da origem	sim
DOW_SIN	calendário cíclico	dia da semana da origem	sim
DOW_COS	calendário cíclico	dia da semana da origem	sim
MONTH_SIN	calendário cíclico	mês da origem	sim
MONTH_COS	calendário cíclico	mês da origem	sim
GOLD_LAG_1	lag de preço	preço de uma observação bruta anterior	sim
GOLD_LAG_5	lag de preço	preço de cinco observações brutas anteriores	sim
GOLD_LAG_20	lag de preço	preço de vinte observações brutas anteriores	sim
GOLD_ROLLING_MEAN_5	janela móvel de preço	média dos cinco preços anteriores à origem	sim
GOLD_ROLLING_STD_5	janela móvel de volatilidade	desvio padrão dos cinco preços anteriores à origem	sim

STL robusta no treino - período 5





4. Protocolo experimental e tuning congelado

A base foi dividida cronologicamente em 70% treino, 15% validação e 15% teste. O walk-forward usa janela expansiva, horizonte de uma observação e passo cinco, com 296 origens de validação e 296 de teste. Os quatro modelos compartilham origens, datas-alvo e `Y_TRUE`.

Tuning ocorreu somente em treino e validação. O teste final avaliou configurações congeladas: SARIMAX $(0,1,2) \times (0,0,1,5)$; Holt-Winters aditivo com período 5; RF com 300 árvores, profundidade 20, folha mínima 5, divisão mínima 10 e `max_features=1.0`; PLS com 11 componentes. Nenhuma decisão foi reaberta nesta finalização.

model	parameters	validation_mae	n_candidates
SARIMAX	<code>{"order": [0, 1, 2], "seasonal_order": [0, 0, 1, 5]}</code>	2.9844	5
Holt_Winters	<code>{"damped_trend": false, "seasonal": "add", "seasonal_periods": 5, "trend": "add"}</code>	2.9760	15
Random_Forest	<code>{"max_depth": 20, "max_features": 1.0, "min_samples_leaf": 5, "min_samples_split": 10, "n_estimators": 300}</code>	3.3263	12
PLS_Regression	<code>{"n_components": 11}</code>	2.9701	12



5. MAE, persistência e mudança de dificuldade

MAE está expresso em USD por onça troy. Nas mesmas 296 origens de teste, o movimento absoluto médio origem-alvo foi 11,6377 e a mediana foi 8,50. Holt-Winters teve MAE equivalente a aproximadamente 99,1% desse movimento médio: é o menor erro formal, mas sua melhora sobre persistência foi inferior a 1%.

O PLS teve MAE de validação 2,9701 e MAE de teste 11,6002. Não há mudança de unidade: são dois blocos temporais diferentes. O histórico completo teve movimento absoluto médio de cerca de 3,8893 USD/onça, contra 11,6377 nas origens oficiais de teste. A diferença mostra aumento importante de escala e volatilidade no teste, sem provar uma causa econômica específica.

Persistência é diagnóstico, não quinto modelo oficial. Ela é especialmente relevante para preços em horizonte curto e impede que pequenas diferenças sejam interpretadas como grande ganho preditivo.


model	mae	baseline_persistence_mae	improvement_pct_vs_persistence
Holt_Winters	11.5331	11.6377	0.8986
SARIMAX	11.5988	11.6377	0.3336
PLS_Regression	11.6002	11.6377	0.3219
Random_Forest	14.2826	11.6377	-22.7275

6. Resíduos e Ljung-Box

Os resíduos fora da amostra são `real - previsto`. Holt-Winters e PLS tiveram média próxima de zero e nenhuma rejeição nos 20 lags avaliados. SARIMAX teve uma rejeição isolada. RF apresentou três rejeições, maior dispersão e viés médio positivo, compatível com subestimação média e estrutura residual remanescente.

O Ljung-Box avalia autocorrelação conjunta até cada lag. Ausência de rejeição não prova independência perfeita; rejeições pontuais também não bastam para explicar todo o erro. A tabela completa de 80 resultados fica no apêndice técnico.

model	media_residuos	desvio_padrao_residuos	rejected_lags_5pct	p_value_lag_20
Holt_Winters	0.1131	15.7363	0	0.4041
PLS_Regression	0.2337	15.8807	0	0.3550
Random_Forest	3.1615	20.5757	3	0.4008
SARIMAX	0.3621	15.7470	1	0.3162




7. Importância das features


No RF, a importância nativa é dominada por `GOLD_PRICE` e `GOLD_LAG_1`. No PLS, coeficientes padronizados, VIP e permutation importance destacam preço atual, lag 1, média móvel e lags 5/20. A leitura é coerente com um horizonte de uma observação, no qual persistência e memória recente são fortes.

Importância não implica causalidade. Features correlacionadas podem dividir importância; sinais de coeficientes podem variar sob colinearidade; e externas com contribuição marginal pequena neste recorte não são evidência de ausência de relação econômica em outros regimes ou horizontes.

model	feature	vip_score	permutation_mean	permutation_rank
PLS_Regression	GOLD_PRICE	1.5003	347.9654	1
PLS_Regression	GOLD_LAG_1	1.4993	30.9009	2
PLS_Regression	GOLD_ROLLING_MEAN_5	1.4979	5.3264	3
PLS_Regression	GOLD_LAG_5	1.4958	1.4682	4
PLS_Regression	GOLD_LAG_20	1.4855	0.9784	5
Random_Forest	GOLD_PRICE	NaN	4.1544	1
Random_Forest	GOLD_LAG_1	NaN	0.2050	2
Random_Forest	FED_FUNDS_RATE	NaN	0.0253	3
Random_Forest	GOLD_ROLLING_STD_5	NaN	0.0027	4
Random_Forest	DOW_COS	NaN	0.0016	5



PLS_Regression: Permutation Importance pós-seleção




PLS Regression aplicado à Base Ouro

Item	Evidência congelada
observações modeláveis / features	9.864 / 12
horizonte	1 observação
origens de validação / teste	296 / 296
busca de componentes	1 a 12
componente escolhido	11
MAE validação / teste	2,9701 / 11,6002 USD por onça
posição do PLS	3º
melhor modelo	Holt-Winters, MAE 11,5331

Preço atual, lag 1, média móvel e lags 5/20 concentram a interpretação por coeficientes, VIP e permutação. O resultado de 11 componentes indica pouca compressão, não 91,7% de variância explicada. Validação e teste pertencem a períodos diferentes, por isso os MAEs não medem a mesma dificuldade temporal.

Limitações: série até 2014, horizonte curto, externas conservadoras, colinearidade e um único período final. Ouro é o primeiro estudo de caso completo, não uma conclusão geral sobre PLS.

dataset	model	feature	native_importance	standardized_coefficient	vip_score	permutation_mean	permutation_std	split	is_ex
gold	PLS_Regression	GOLD_PRICE	140.2071	140.2071	1.5003	347.9654	13.4651	test_final_post_selection	False
gold	PLS_Regression	GOLD_LAG_1	15.9690	15.9690	1.4993	30.9009	1.4033	test_final_post_selection	False
gold	PLS_Regression	GOLD_ROLLING_MEAN_5	4.6213	-4.6213	1.4979	5.3264	0.3993	test_final_post_selection	False
gold	PLS_Regression	GOLD_LAG_5	2.3831	2.3831	1.4958	1.4682	0.2105	test_final_post_selection	False
gold	PLS_Regression	GOLD_LAG_20	1.7886	-1.7886	1.4855	0.9784	0.1501	test_final_post_selection	False
gold	PLS_Regression	GOLD_ROLLING_STD_5	0.1939	-0.1939	0.7747	0.0141	0.0209	test_final_post_selection	False
gold	PLS_Regression	TREASURY_10Y	0.1354	-0.1354	0.3435	0.0016	0.0012	test_final_post_selection	True
gold	PLS_Regression	MONTH_COS	0.0249	0.0249	0.0876	0.0005	0.0011	test_final_post_selection	False




Base Ouro - V2 complementar: LEVEL, DELTA e LOG_RETURN

A V2 foi concluída como estudo complementar no commit `d6f67bd` . Ela não reabre o ranking V1. No RF A8, transformar LEVEL em DELTA ou LOG_RETURN reduziu fortemente o erro reconstruído em preço: 39,5007 no nível, 12,1579 em delta e 11,7850 em log-retorno. Mesmo assim, DELTA e LOG_RETURN A8 não superaram persistência.

O menor MAE experimental foi RF/LOG_RETURN/A3, 11,2986, ganho de 0,3390 USD/onça (2,91%) sobre persistência e acurácia direcional de 53,72%. Esse resultado é `INFORMATIVE` , pois surgiu em especificação experimental posterior. Ele orienta pesquisa futura, mas não é sucessor oficial de Holt-Winters.

model	feature_set	target	mae_usd	directional_accuracy	status
RF	A8_technical_all_core	LEVEL	39.5007	0.5169	INFORMATIVE
RF	A8_technical_all_core	DELTA	12.1579	0.4932	INFORMATIVE
RF	A8_technical_all_core	LOG_RETURN	11.7850	0.5304	INFORMATIVE
RF	A3_gold_technical_no_raw	LOG_RETURN	11.2986	0.5372	INFORMATIVE



A3 LOG_RETURN é informativo e não substitui o ranking oficial V1.

Base Ouro - V2 complementar: ablation, extrapolação, drift e redundância

Na ablation RF LEVEL FULL, remover `GOLD_PRICE` piorou o MAE em 2,0914 USD/onça, cerca de 14%. Remover todos os lags trouxe melhora pequena de 0,2929, mas o resultado continuou pior que persistência. Usar somente exógenas produziu MAE 38,1406. Mais features não garantiram melhora, e exógenas não substituíram a dinâmica autorregressiva neste horizonte.


No diagnóstico RF A8, `y_train` variou de 252,90 a 725,75 e `y_test` de 647,75 a 1.877,75. Em 281 de 296 origens, 94,9%, o alvo real superou o máximo visto no treino. Como árvores predizem por médias em folhas, não extrapolam naturalmente novos níveis. Drift em WTI, juros, dólar, índice acionário e volatilidade do ouro agravou a mudança de distribuição.

Também houve redundância: DGS2 e seu lag 1 (~0,9997), VIX e seu lag (~0,9818), e distância da média 20 com momentum 10 (~0,9289). A estabilidade temporal das importâncias é `NOT_ASSESSABLE_SINGLE_TEST_PERIOD` ; há um único período de teste, logo drift e permutação são diagnósticos descritivos.

feature_set	mae_usd	absolute_difference_vs_full	n_features
FULL	14.9906	0.0000	39
FULL_without_GOLD_PRICE	17.0820	2.0914	38
FULL_without_gold_lags	14.6976	-0.2929	23
A4_exogenous_only	38.1406	23.1500	7


feature	standardized_mean_shift
DCOILWTICO	3.4250
DGS2	-2.1746
dgs2_lag1	-2.1710
yield_curve_slope	1.3751
DTWEXB	-1.1297
gold_rv_60	1.0256
NASDAQCOM	0.8929
gold_rv_20	0.8580

V2: ablation resumida do RF em LEVEL



Resultados diagnósticos: não autorizam seleção pós-teste.

V2: extrapolação e mudança de distribuição no RF A8



281/296 alvos (94,9%) acima
do máximo observado no treino

Base Ouro - validação V2 e ressalva de metadado

A evidência final da V2 registra 99 experimentos canônicos, todos com 296 origens, previsões finitas, origens únicas, MAE reproduzido e reconstrução correta de preço para DELTA e LOG_RETURN. A Stage B está concluída; o antigo `V2_STATUS.md` com itens `deferred/not run` ficou desatualizado diante dos achados e da validação final de `d6f67bd`.

O estado correto é **PASS_WITH_METADATA_RECONCILIATION_REQUIRED**. Nos arquivos brutos V2, `target_date` contém a data da origem. As tabelas consolidadas recuperam a data-alvo correta pelo manifesto V1 congelado. A reconciliação altera apenas o rótulo de metadado: previsões, `Y_TRUE`, as 296 origens e os MAEs permanecem intactos.

status	experimentos	origens_por_experimento	V1_byte_identical	Stage_B
PASS_WITH_METADATA_RECONCILIATION_REQUIRED	99	296	True	completed

Conclusão local - Base Ouro

As conclusões estão limitadas à série histórica até 2014, horizonte de uma observação e calendário irregular. As externas seguem regra conservadora, sem vintages intradiários completos. O ganho do melhor modelo sobre persistência é pequeno. A importância não é causal e sua estabilidade entre regimes não foi demonstrada. A V2 explorou um único teste e não autoriza seleção pós-teste.

A conclusão oficial permanece: Holt-Winters 11,5331; SARIMAX 11,5988; PLS 11,6002; Random Forest 14,2826. Persistência marcou 11,6377 fora do ranking. Os três primeiros ficaram praticamente empatados. RF em LEVEL foi prejudicado por extrapolação, drift, redundância, maior dispersão e estrutura residual remanescente.

A V2 mostra que DELTA e LOG_RETURN são caminhos promissores para um protocolo futuro com seleção pré-teste, períodos independentes e dados mais recentes. Nesta entrega, V1 é a referência oficial e V2 é explicação complementar.

camada	uso	altera ranking V1
V1 oficial	ranking e conclusão	não
Baseline diagnóstico	contextualizar dificuldade	não
V2 complementar	explicar limites e orientar pesquisa	não

Referências, apêndice e governança

As referências completas estão em `docs/relatorios/grupo5/referencias.md` , separadas entre fonte institucional, URL de aquisição, séries externas, artigos e bibliotecas. O apêndice técnico lista protocolo, tuning, resíduos, Ljung-Box, auditorias, V2, hashes e ressalvas. O checklist distingue requisitos locais de itens dependentes das cinco bases ou do grupo.

Artefatos congelados protegidos: base modelada, `predictions.csv` , `metrics.csv` , `hyperparameters.csv` , `protocol.json` e os 24 notebooks técnicos da V1. A finalização não executou tuning, treinamento, walk-forward ou otimização.

Documentos associados: `docs/relatorios/grupo5/apendice_tecnico.md` , `analyses/grupo5/auditorias/relatorio_ouro/CHECKLIST_ATIVIDADE_OURO.md` , `docs/relatorios/grupo5/roteiro_apresentacao_ouro.md` , `docs/relatorios/grupo5/referencias.md` e `analyses/grupo5/auditorias/relatorio_ouro/MANIFESTO_ENTREGA_OURO.md` .

artefato	SHA-256
gold_daily_modeling.csv	38622FE40A18C3E94B89971488468F762353ED4234234E054F0439918CB5D1AC
predictions.csv	83C52112B6DDE640F520F3F870D30F0927CB4A03103098B4C284B24662AC6EC0
metrics.csv	F9FE5418EB7F5F14357ADA49BA64B7264282A148B81D3B2F792AE673F708E92E
hyperparameters.csv	4CB56A13CB6CC3A31B8ACC60E2BB3DD3ECEAE1448EB698D39B1540BFC5203886
protocol.json	21F258988ABF0E585F426137F8FD16943997985C01F0AAFE204445F6481D74C5