

Base 3 — PM2.5 horário em Aotizhongxin

Grupo 5 • horizonte de 1 hora • protocolo único para SARIMAX, Holt-Winters, Random Forest e PLS

Resumo

Os quatro modelos previram o PM2.5 da hora seguinte nas mesmas 6023 origens do teste, de 16 de maio de 2016 a 28 de fevereiro de 2017. O menor MAE foi $9,5131 \mu\text{g}/\text{m}^3$, do Random Forest. A soma dos tempos dos quatro modelos é 17,54 minutos.

Soma dos tempos de cada modelo. Holt-Winters e SARIMAX permanecem da execução anterior; Random Forest e PLS foram reestimados com a grade ampliada.

A validação escolheu suavização exponencial simples, sem tendência e sem sazonalidade. As versões com sazonalidade de 24 horas tiveram erro bem maior na validação, no mesmo sentido da força sazonal baixa medida no STL. O SARIMAX comparou ordens sazonais e não sazonais por AIC e BIC no fim do treino e, para a previsão, ficou com a ordem de menor MAE na validação. Random Forest e PLS usaram a mesma matriz de 17 preditores, sem a meteorologia de Guanyuan.

Participantes e escopo

Este relatório cobre somente a Base 3. O repositório não registra os nomes dos integrantes. As outras quatro bases ficam fora desta entrega.

A fonte é o conjunto Beijing Multi-Site Air-Quality Data, estação Aotizhongxin, de 1º de março de 2013 a 28 de fevereiro de 2017, em frequência horária. O alvo é o PM2.5 em $\mu\text{g}/\text{m}^3$. As estações externas usadas na previsão são Changping e Wanliu.

Base e preparo

A série preparada tem 35.064 horas. Havia 925 valores ausentes de PM2.5; eles foram preservados no alvo. Os preditores receberam preenchimento para a frente, só com o passado. Não houve preenchimento para trás nem interpolação na base de modelagem. A interpolação usada no STL ficou restrita à cópia da decomposição.

A matriz exploratória de 671 colunas permanece em `features_base3.csv`. A modelagem de Random Forest e PLS usa `features_modelagem_base3.csv`, com 19494 horas de treino, 4545 de validação e 6023 de teste antes do alinhamento final das origens. Na previsão de $PM_{2.5}(t+1)$, as medições entram com o valor conhecido em t . O calendário é o da hora prevista, porque a hora e o dia da semana já são conhecidos na origem.

DEWP, PRES, RAIN e WSPM de Guanyuan repetem a estação local nos arquivos congelados. Essa meteorologia foi excluída. O PM2.5 de Guanyuan é distinto, mas não entrou na matriz reduzida.

Preditores compartilhados

preditor	disponível em
pm25_t	origem t
pm25_t_1	origem t
pm25_t_2	origem t
pm25_t_23	origem t
pm25_roll_mean_3	origem t
pm25_roll_mean_24	origem t
local_PM10	origem t
local_CO	origem t
local_TEMP	origem t
local_WSPM	origem t
local_DEWP	origem t
Changping_PM2.5	origem t
Wanliu_PM2.5	origem t
target_hour_sin	t+1, já conhecido
target_hour_cos	t+1, já conhecido
target_dow_sin	t+1, já conhecido
target_dow_cos	t+1, já conhecido

Decomposição STL

O STL principal usa período de 24 horas. A força sazonal foi 0,013 e a força de tendência foi 0,287. A sazonalidade diária explica pouco da variância do PM2.5 nesta estação. Por isso a busca sazonal do SARIMAX e a grade do Holt-Winters foram mantidas, mas a escolha final obedece ao MAE da validação, não à presença do termo sazonal.

Protocolo walk-forward

O horizonte é de 1 hora. O treino interno vai até 2015-09-25 06:00. A validação interna vai até 2016-05-16 04:00. O teste começa em 2016-05-16 05:00. Nenhum hiperparâmetro foi escolhido no teste.

Holt-Winters é reestimado em toda origem, numa janela de 21 dias do PM2.5. Se a janela ainda tem buraco depois do preenchimento causal de até 24 horas, o ajuste usa só o trecho contínuo após o último buraco. Random Forest, PLS e SARIMAX reestimam os parâmetros uma vez por dia. Dentro do dia, cada hora usa a informação já observada até aquela origem, com os parâmetros do dia congelados. No SARIMAX isso é um **append** sem novo ajuste. No Random Forest e no PLS, os preditores da hora entram na previsão, mas o ajuste não vê as horas daquele dia.

Previsões negativas são truncadas em zero. Se um ajuste falha, a hora recebe a persistência do último PM2.5 observado e a falha é contada. Holt-Winters recorreu à persistência em 24 horas. Depois da geração, as quatro séries ficam restritas à interseção das origens. Nesta execução, essa interseção tem 6023 horas.

Modelos e ajuste

Holt-Winters

A validação escolheu suavização exponencial simples, sem tendência e sem sazonalidade. As versões com sazonalidade de 24 horas tiveram erro bem maior na validação, no mesmo sentido da força sazonal baixa medida no STL. A referência é univariada: não usa estação externa nem calendário como regressor.

SARIMAX

AIC e BIC foram calculados uma vez, nos últimos 14 dias de treino até 2015-09-25 06:00. As ordens sazonais tiveram AIC menor. A escolha da previsão, porém, é o MAE da validação, na mesma grade. As exógenas são o calendário da hora e a defasagem de 1 hora de PM10, temperatura, velocidade do vento e PM2.5 de Changping. Cada ajuste diário usa os últimos 14 dias.

order	seasonal_order	aic	bic	converged	seconds
(0, 1, 1)	(0, 1, 1, 24)	2.487,9	2.528,1	True	0.9
(1, 0, 1)	(1, 0, 0, 24)	2.736,0	2.780,9	True	0.52
(1, 1, 1)	(0, 0, 0, 0)	2.876,8	2.918,7	True	0.09
(0, 1, 1)	(0, 0, 0, 0)	2.879,6	2.917,6	True	0.06
(1, 0, 1)	(0, 0, 0, 0)	2.912,6	2.954,5	True	0.05

Random Forest e PLS

Os dois modelos compartilham os 17 preditores. O PLS padroniza os preditores em cada ajuste (`scale=True`). A floresta escolhida tem 40 árvores, profundidade 12, folha mínima 5, divisão mínima 2 e `max_features` 0.5, com `random_state` 42. A grade abaixo é a validação interna. A validação escolheu 14 componentes, no interior da grade.

modelo	parameters	MAE_validation	n_predictions	seconds	fallbacks
Holt Winters	damped_trend=False, seasonal=None, trend=None	13,9625	4545	3.6	2.0
Holt Winters	damped_trend=False, seasonal=None, trend=add	14,9759	4545	12.8	2.0
Holt Winters	damped_trend=False, seasonal=add, trend=None	50,6145	4545	13.3	2.0
Holt Winters	damped_trend=True, seasonal=add, trend=add	56,9684	4545	25.8	2.0
Holt Winters	damped_trend=False, seasonal=add, trend=add	69,1196	4545	23.2	2.0
SARIMAX	order=[0, 1, 1], seasonal_order=[0, 0, 0, 0], trend=n	11,0655	4545	19.4	0.0
SARIMAX	order=[1, 1, 1], seasonal_order=[0, 0, 0, 0], trend=n	11,1331	4545	22.4	0.0
SARIMAX	order=[0, 1, 1], seasonal_order=[0, 1, 1, 24], trend=n	12,2037	4545	252.2	0.0
SARIMAX	order=[1, 0, 1], seasonal_order=[0, 0, 0, 0], trend=n	12,7224	4545	20.0	0.0
SARIMAX	order=[1, 0, 1], seasonal_order=[1, 0, 0, 24], trend=n	13,2912	4545	140.6	0.0
Random Forest	max_depth=12, max_features=0.5, min_samples_leaf=5, min_samples_split=2, n_estimators=40	10,7430	4545	80.7	nan
Random Forest	max_depth=12, max_features=sqrt, min_samples_leaf=5, min_samples_split=2, n_estimators=80	11,1995	4545	80.9	nan
Random Forest	max_depth=12, max_features=sqrt, min_samples_leaf=5, min_samples_split=2, n_estimators=40	11,2564	4545	44.6	nan
Random Forest	max_depth=12, max_features=sqrt, min_samples_leaf=5, min_samples_split=10, n_estimators=40	11,2564	4545	43.2	nan

modelo	parameters	MAE_validation	n_predictions	seconds	fallbacks
Random Forest	max_depth=16, max_features=sqrt, min_samples_leaf=2, min_samples_split=2, n_estimators=40	11,3105	4545	61.7	nan
Random Forest	max_depth=8, max_features=sqrt, min_samples_leaf=5, min_samples_split=2, n_estimators=40	11,7257	4545	32.6	nan
PLS Regression	n_components=14	10,6265	4545	2.3	nan
PLS Regression	n_components=16	10,6350	4545	2.6	nan
PLS Regression	n_components=12	10,6577	4545	2.0	nan
PLS Regression	n_components=8	10,8941	4545	1.4	nan
PLS Regression	n_components=4	13,4410	4545	0.8	nan
PLS Regression	n_components=2	15,6024	4545	0.6	nan

MAE no teste

O MAE abaixo usa somente previsões fora da amostra, nas mesmas origens. Ele não deve ser somado ao MAE de outra base: a escala do PM2.5 não é a escala das demais séries do grupo.

model	MAE_test	n_predictions	config
Random_Forest	9,5131	6023	max_depth=12, max_features=0.5, min_samples_leaf=5, min_samples_split=2, n_estimators=40
PLS_Regression	9,6643	6023	n_components=14
SARIMAX	10,2225	6023	order=[0, 1, 1], seasonal_order=[0, 0, 0, 0], trend=n
Holt_Winters	12,9122	6023	damped_trend=False, seasonal=None, trend=None



Outras métricas

model	MAE	RMSE	MAPE_pct	R2	bias	n_predictions
Random_Forest	9,5131	17,7236	24,62	0,9582	0,5877	6023
PLS_Regression	9,6643	17,6099	26,13	0,9587	0,5480	6023
SARIMAX	10,2225	18,0349	29,44	0,9567	-0,1011	6023
Holt_Winters	12,9122	23,7468	33,29	0,9249	0,0559	6023

O erro médio (viés) é observado menos previsão. Valor positivo indica previsão abaixo do PM2.5 realizado.

Resíduos

Cada painel é a série do resíduo no teste. Em seguida está a autocorrelação até o lag 48 e o teste de Ljung-Box nos lags 10, 24 e 48.



model	lag	lb_stat	lb_pvalue	n_residuals
Holt_Winters	10	2.488,4	0	6023
Holt_Winters	24	2.627,9	0	6023
Holt_Winters	48	2.971,5	0	6023
SARIMAX	10	127,2	1.72e-22	6023
SARIMAX	24	157,2	1.51e-21	6023
SARIMAX	48	220,9	5.18e-24	6023
Random_Forest	10	255,3	4.18e-49	6023
Random_Forest	24	304,9	1.74e-50	6023
Random_Forest	48	357,9	5.47e-49	6023
PLS_Regression	10	76,3	2.61e-12	6023
PLS_Regression	24	122,1	4.09e-15	6023
PLS_Regression	48	173,0	5.1e-16	6023

model	bias	residual_std	interpretacao
Holt_Winters	0,056	23,747	O erro médio é 0.06 $\mu\text{g}/\text{m}^3$, então a previsão fica abaixo do observado. O desvio-padrão do resíduo é 23.75 $\mu\text{g}/\text{m}^3$. No lag 24, ainda há autocorrelação nos resíduos ($p=0$).
SARIMAX	-0,101	18,035	O erro médio é -0.10 $\mu\text{g}/\text{m}^3$, então a previsão fica acima do observado. O desvio-padrão do resíduo é 18.03 $\mu\text{g}/\text{m}^3$. No lag 24, ainda há autocorrelação nos resíduos ($p=1.51\text{e-}21$).
Random_Forest	0,588	17,714	O erro médio é 0.59 $\mu\text{g}/\text{m}^3$, então a previsão fica abaixo do observado. O desvio-padrão do resíduo é 17.71 $\mu\text{g}/\text{m}^3$. No lag 24, ainda há autocorrelação nos resíduos ($p=1.74\text{e-}50$).
PLS_Regression	0,548	17,601	O erro médio é 0.55 $\mu\text{g}/\text{m}^3$, então a previsão fica abaixo do observado. O desvio-padrão do resíduo é 17.60 $\mu\text{g}/\text{m}^3$. No lag 24, ainda há autocorrelação nos resíduos ($p=4.09\text{e-}15$).

Importância das variáveis

A importância do Random Forest é a redução média de impureza de uma floresta ajustada só no treino interno, com a configuração escolhida na validação. Não é a média das florestas diárias do walk-forward. Preditores de PM2.5 muito correlacionados dividem crédito entre si.

feature	importance
pm25_t	0,547
pm25_roll_mean_3	0,231
Wanliu_PM2.5	0,095
local_PM10	0,044
pm25_t_1	0,039
pm25_t_2	0,016
pm25_roll_mean_24	0,009
Changping_PM2.5	0,008
local_WSPM	0,003
local_DEWP	0,002
local_TEMP	0,001
pm25_t_23	0,001
local_CO	0,001
target_hour_sin	0,001
target_hour_cos	0,001
target_dow_sin	0,000
target_dow_cos	0,000

O VIP do PLS também vem de um único ajuste no treino interno, com o número de componentes escolhido na validação e com padronização. VIP acima de 1 indica preditor mais útil que a média para explicar o PM2.5 da hora seguinte nesse ajuste. A limitação é a mesma: o número não descreve cada janela diária, e lags colineares repartem a importância.

feature	vip
pm25_t	1,520
pm25_roll_mean_3	1,430
pm25_t_1	1,411
Wanliu_PM2.5	1,410
pm25_t_2	1,355
Changping_PM2.5	1,290
local_PM10	1,279
local_CO	1,111
pm25_roll_mean_24	1,108
pm25_t_23	0,688
local_WSPM	0,445
local_DEWP	0,383

feature	vip
local_TEMP	0,330
target_hour_sin	0,224
target_dow_sin	0,179
target_hour_cos	0,176
target_dow_cos	0,156

Os coeficientes abaixo são do mesmo ajuste, já na escala padronizada. O arquivo `pls_feature_importance.csv` guarda esses coeficientes. VIP e coeficiente podem ordenar as colunas de formas diferentes: o VIP mede a contribuição para os componentes e o coeficiente é o peso depois dessa projeção. Lags colineares repartem os dois números.

feature	standardized_coefficient	abs_coefficient
target_hour_sin	-1,934	1,934
local_WSPM	-1,353	1,353
pm25_t	0,976	0,976
target_hour_cos	-0,759	0,759
target_dow_cos	-0,402	0,402
pm25_t_1	-0,327	0,327
local_TEMP	-0,237	0,237
local_DEWP	0,208	0,208
pm25_roll_mean_3	0,199	0,199
Changping_PM2.5	0,083	0,083
pm25_t_2	-0,073	0,073
Wanliu_PM2.5	0,073	0,073
target_dow_sin	-0,041	0,041
local_PM10	0,033	0,033
pm25_roll_mean_24	-0,008	0,008
pm25_t_23	0,002	0,002
local_CO	0,000	0,000

As variáveis externas com VIP ou importância altos são medições da origem t: PM2.5 de Wanliu e de Changping, além de PM10, CO, temperatura, vento e ponto de orvalho locais. Nenhuma delas usa valor de t+1.

PLS em linguagem direta

Com muitos preditores parecidos, uma regressão comum fica instável: o coeficiente de um lag compete com o do lag vizinho e os dois podem sair grandes e com sinais opostos. O PLS evita esse passo. Ele constrói poucas combinações dos preditores, chamadas componentes, escolhidas para acompanhar o PM2.5 da hora seguinte, e só então faz a regressão nessas combinações.

A diferença para o componente principal comum é o critério. O componente principal resume a variação dos preditores sem olhar o alvo. O componente do PLS olha os dois lados: ele privilegia a direção de X que anda junto com y. Por isso um preditor pode variar muito e mesmo assim receber pouco peso, se essa variação não ajudar a prever o PM2.5.

Nesta base a grade pediu 2, 4, 8, 12, 14, 16 componentes. Dezesesseis é o maior número usado: com 17 preditores, o passo seguinte já ocupa todas as colunas. O número vencedor está na tabela de ajuste e fica fixo no teste. Cada dia reestima os componentes com o passado disponível até a véspera, sempre com os preditores padronizados. O VIP e os coeficientes padronizados vêm de um único ajuste no treino interno. Eles ajudam a leitura e não substituem o MAE do teste.

Conclusões

Nas 6023 horas comuns, Random Forest teve o menor MAE, 9,5131 $\mu\text{g}/\text{m}^3$. A comparação é direta porque a origem, o horizonte e o período de teste são os mesmos.

A sazonalidade de 24 horas aparece no calendário, mas a força sazonal do STL é 0,013. Na validação, Holt-Winters com período 24 perde para a suavização sem sazonalidade. O SARIMAX escolhido foi a ordem (0, 1, 1) com sazonalidade (0, 0, 0, 0). As ordens sazonais tiveram AIC menor na janela final do treino e MAE maior na validação, então não foram para o teste.

A matriz de 17 colunas deixa Random Forest e PLS no mesmo conjunto de informação, com disponibilidade explícita na origem. A meteorologia duplicada de Guanyuan ficou de fora. Os resíduos ainda mostram estrutura, então o erro de uma hora continua informando o erro das horas vizinhas; o MAE resume o tamanho do erro, não a ausência de dependência.

Referências

- Breiman, L. Random Forests. Machine Learning, 2001.
- Chong, I.-G.; Jun, C.-H. Performance of some variable selection methods when multicollinearity is present. Chemometrics and Intelligent Laboratory Systems, 2005.
- Hyndman, R. J.; Athanasopoulos, G. Forecasting: Principles and Practice. OTexts.
- Ljung, G. M.; Box, G. E. P. On a measure of lack of fit in time series models. Biometrika, 1978.
- Wold, S.; Sjöström, M.; Eriksson, L. PLS-regression: a basic tool of chemometrics. Chemometrics and Intelligent Laboratory Systems, 2001.
- Zhang, S. et al. Beijing Multi-Site Air-Quality Data. UCI Machine Learning Repository, 2017.
<https://archive.ics.uci.edu/dataset/501/beijing+multi+site+air+quality+data>

Apêndice — arquivos

- analyses/grupo3/02_modelos/protocolo_final.py — protocolo executado.
- analyses/grupo3/02_modelos/results/protocolo_final.json — tempo e MAE.
- analyses/grupo3/02_modelos/results/validation_protocol.json — cortes e preditores.
- analyses/grupo3/01_dados/outputs/features_modelagem_base3.csv — matriz usada por Random Forest e PLS.
- analyses/grupo3/03_resultados/outputs/ — MAE, resíduos, ACF, VIP e importância.
- Cada modelo guarda previsões, grade e configuração em 02_modelos/<modelo>/results/.

Checksum das bases congeladas

SHA-256 dos arquivos em bases/grupo3, gravado em bases/grupo3/SHA256SUMS.txt.

arquivo	sha256
bases/grupo3/PRSA_Data_Aotizhongxin_20130301-20170228.csv	a94fbcfc71708b6ffdc033360163d91efb7f675e496f6b5860929aa96b96351b
bases/grupo3/externas/PRSA_Data_Changping_20130301-20170228.csv	a2e21402a6d95fb7043f87959e6e3dcbeeb957aac356a6f8028a85b047c772e7
bases/grupo3/externas/PRSA_Data_Guanyuan_20130301-20170228.csv	59390fee3b032597b387491f5230e7edb90a8558e30217ebd6d9befbe669fbf9
bases/grupo3/externas/PRSA_Data_Wanliu_20130301-20170228.csv	0b1a6d754a07f0def2f55434ddfa3870dcd0063b7f766a6f66b6c11bb05a377a